



# 文本生成前沿综述

冯骁骋  
哈尔滨工业大学  
2018.10





# 文本生成

文本生成就是指期待未来有一天计算机能够像人类一样会表达，能够撰写出高质量的自然语言文本。

## 文本 - 文本

- 文本到文本的生成主要指对给定文本进行理解、变换和丰富从而获得新文本的技术



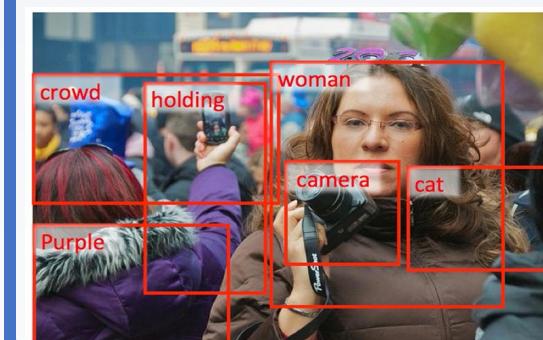
## 数据 - 文本

- 数据到文本的生成指根据给定的数值数据生成相关文本



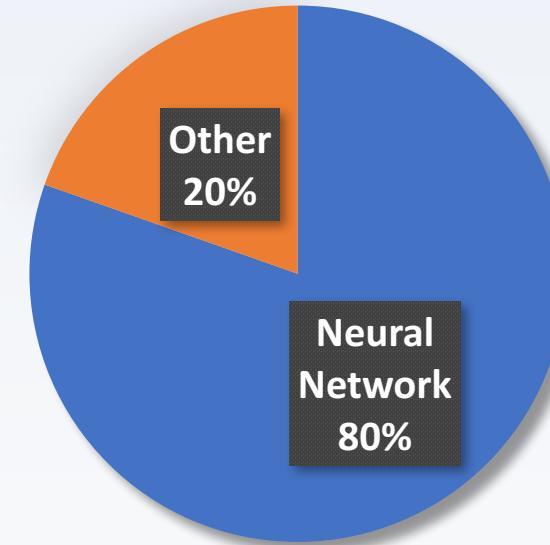
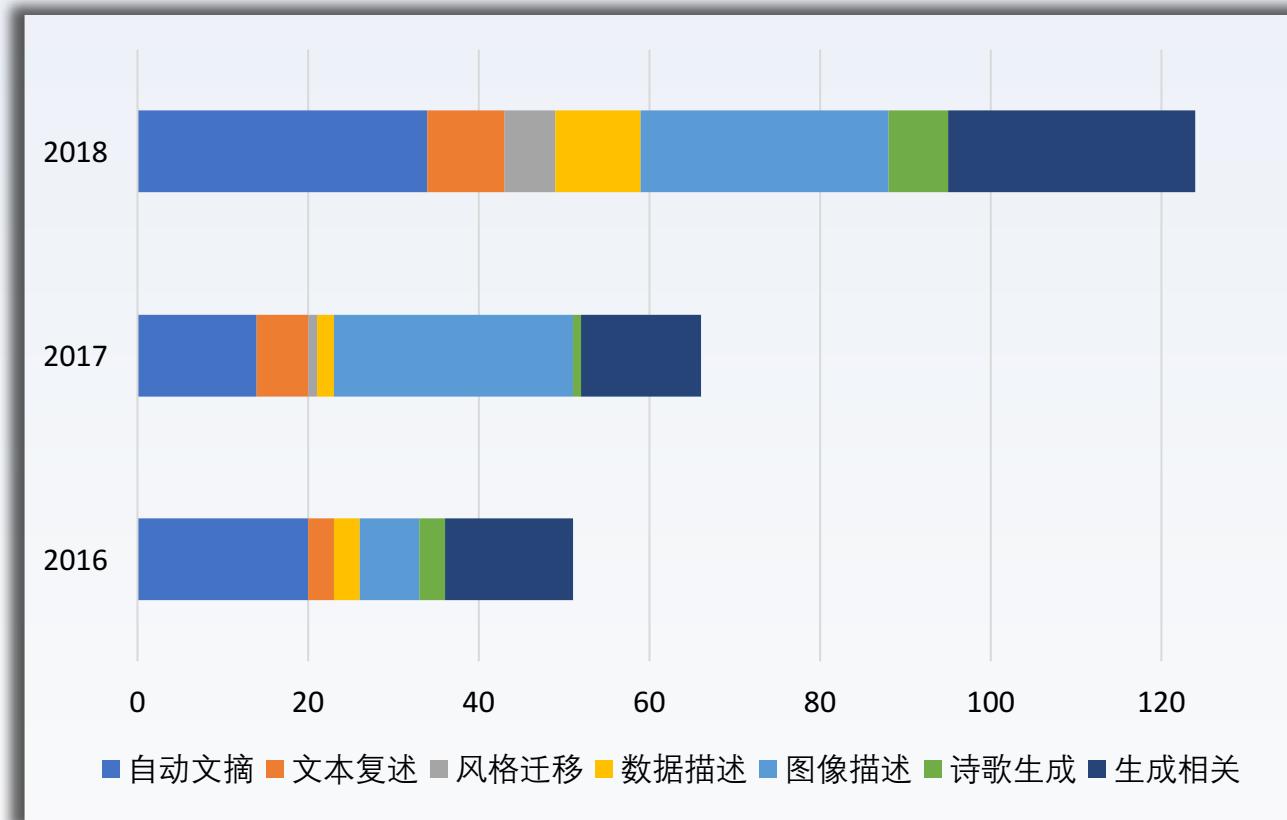
## 图像 - 文本

- 图像到文本的生成是指根据给定的图像生成描述该图像内容的自然语言文本





# 文本生成论文分布



统计结果覆盖 : ACL, EMNLP , NAACL, COLING, AAAI , IJCAI , NIPS ,



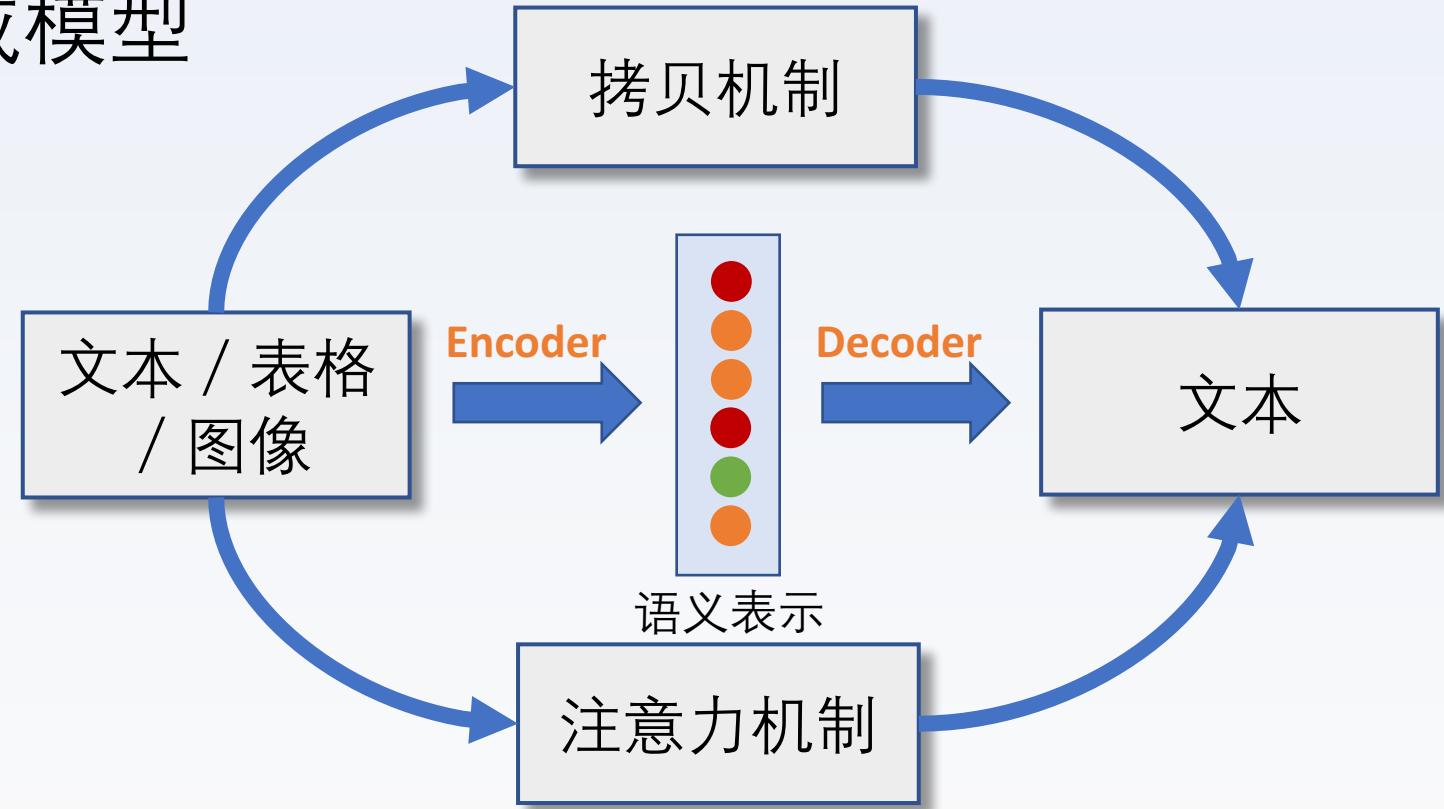


# 文本生成模型

## ❖ 基于神经网络的生成模型

- Encoder-Decoder
- 注意力机制
- 拷贝机制

## ❖ 与任务结合更紧密





# 文本生成发展趋势

- ❖ 趋势一：生成和抽取相结合
- ❖ 趋势二：融合任务相关的背景知识
- ❖ 趋势三：学习语言的不同风格表达
- ❖ 趋势四：借鉴人类写作模式





# 文本生成发展趋势

- ❖ 趋势一：生成和抽取相结合
- ❖ 趋势二：融合任务相关的背景知识
- ❖ 趋势三：学习语言的不同风格表达
- ❖ 趋势四：借鉴人类写作模式





# 趋势一：生成和抽取相结合

❖ 典型任务：自动文摘

❖ 主要问题：

- 抽取式方法：多样性差，不连贯
- 生成式方法：不稳定、难以解释

❖ 解决方案：抽取 + 生成

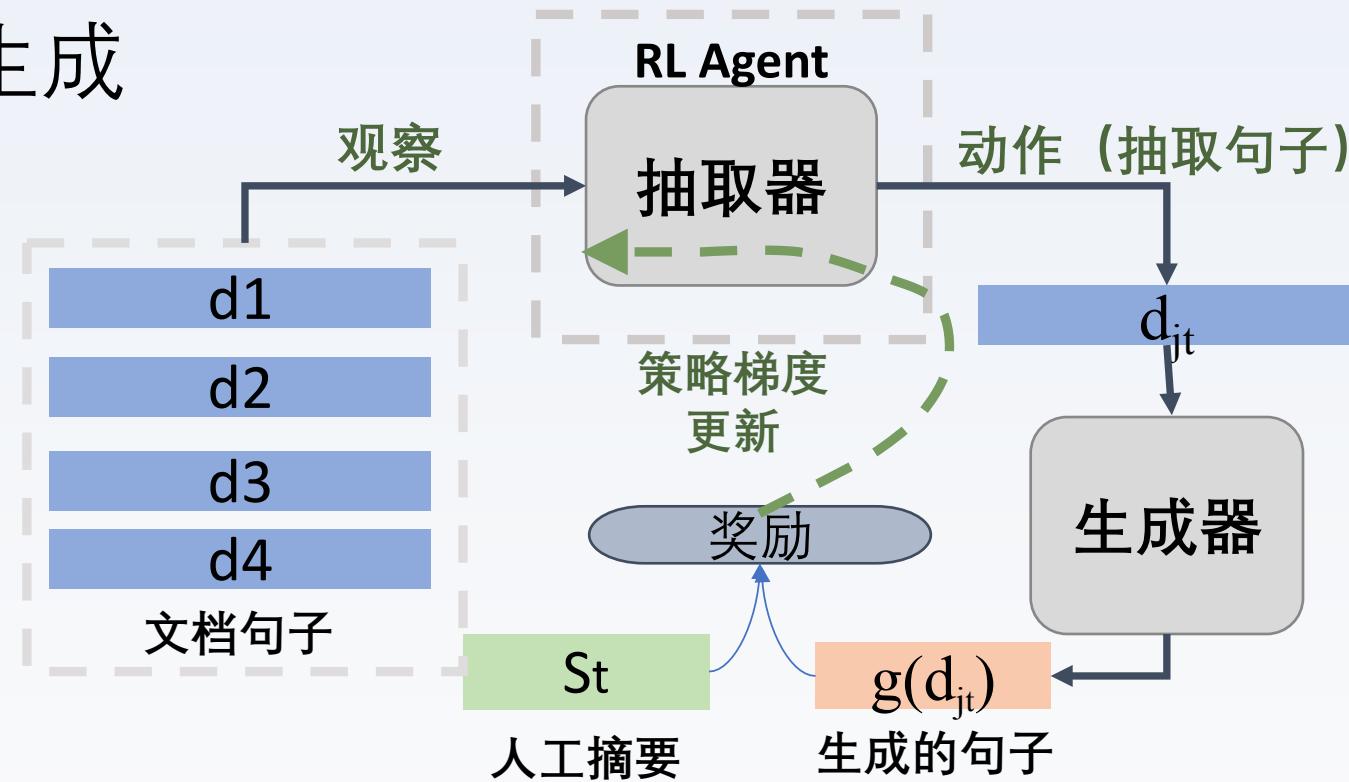
- 联合学习、模型互补





# 趋势一：生成和抽取相结合

❖ 抽取 + 生成





# 趋势一：生成和抽取相结合

## CNN/Daily Mail

	Model	R-1	R-2	R-L
抽取式摘要	LEAD3 (See et al., 2017)	40.34	17.70	36.57
	TEXTRANK (Rehurek et al., 2010)	40.20	17.56	36.44
	SUMMARUNNER (Nallapati et al., 2017)	39.6	16.2	35.3
生成式摘要	Pointer Network (See et al., 2017)	39.53	17.28	36.38
	GAN (Liu et al., 2017)	39.92	17.65	36.71
	CRSUM (Ren et al., 2017)	40.52	18.08	36.81
抽取 + 生成	End2End (Hsu et al., 2018)	40.68	17.70	37.13
	SWAP-NET (Jadhav et al., ACL 2018 )	41.6	18.3	37.7
	Rnn-Ext + RL (Chen et al., ACL 2018)	<b>41.47</b>	<b>18.72</b>	<b>37.76</b>





# 文本生成发展趋势

- ❖ 趋势一：生成和抽取相结合
- ❖ 趋势二：融合任务相关的背景知识
- ❖ 趋势三：学习语言的不同风格表达
- ❖ 趋势四：借鉴人类写作模式





## 趋势二：融合任务相关的背景知识

- ❖ 典型任务：对话生成
- ❖ 主要问题：缺乏个性化和背景知识
- ❖ 解决方案：加入任务相关的背景知识
  - 常识知识
  - 结构语义知识





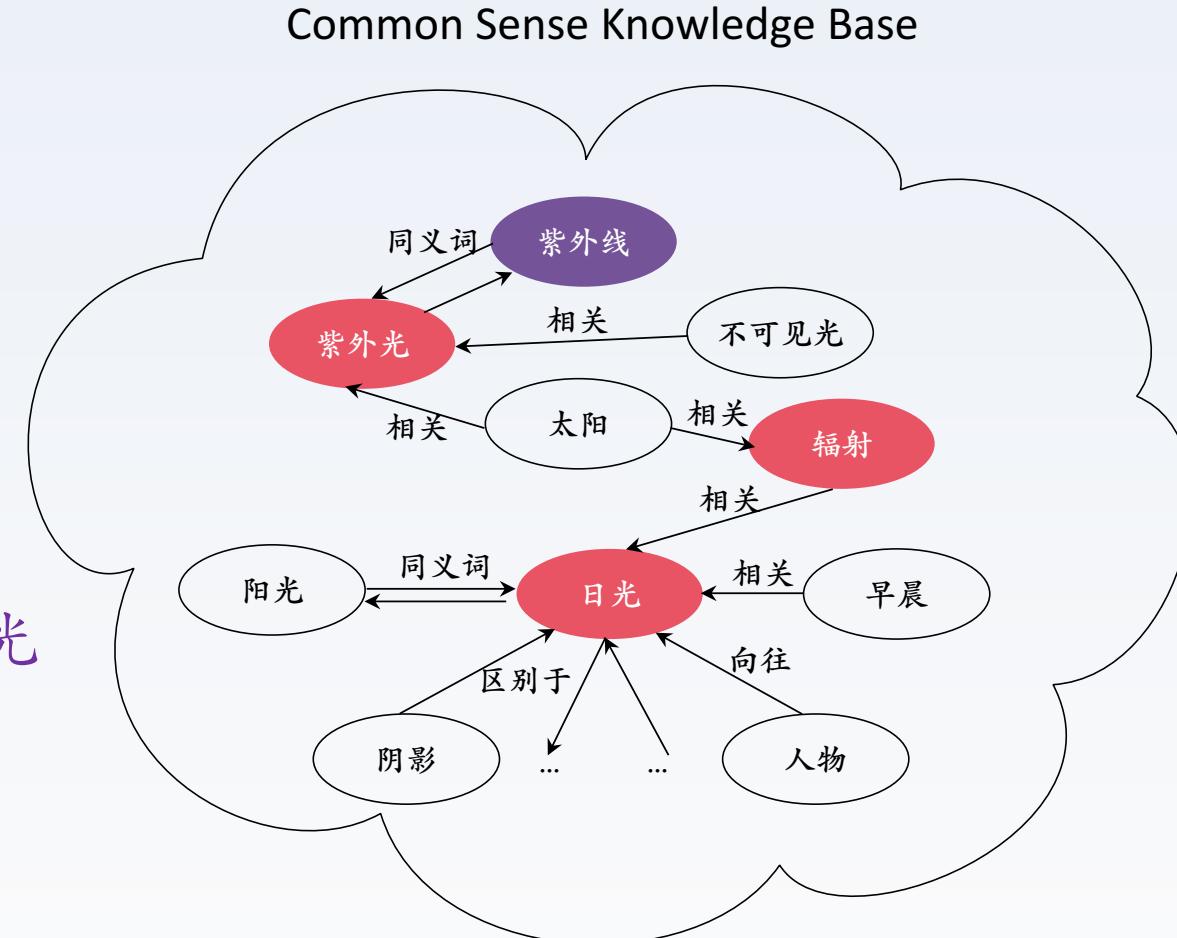
# 趋势二：融合任务相关的背景知识

## ❖ 常识知识

原句：月光缺乏**日光的紫外线**

生成\_1：我不知道你在说什么

生成\_2：我不认为**阳光缺少紫外光**





# 趋势二：融合任务相关的背景知识

## ❖ 结构语义知识

- 结构化数据生成->表格结构
- 图像描述生成->图像语义结构
- 自动文摘->篇章结构



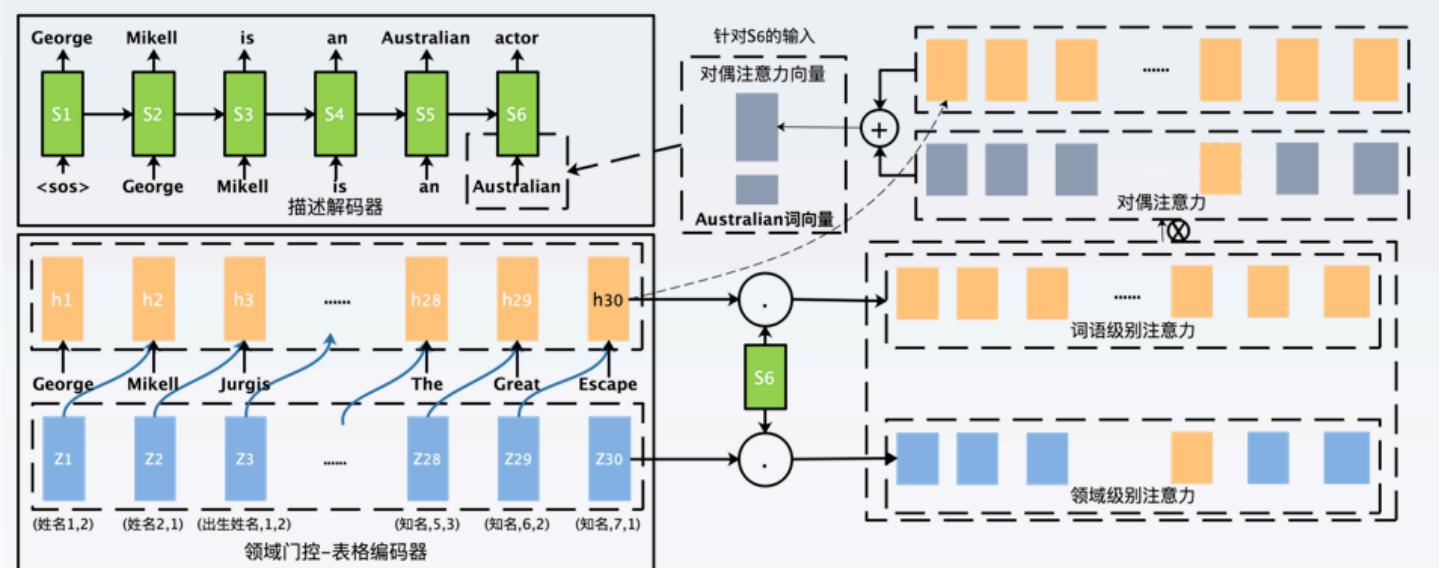


# 趋势二：融合任务相关的背景知识

## ❖ 结构语义知识

➤ 结构化数据生成->表格结构

Table Structure-Aware Model



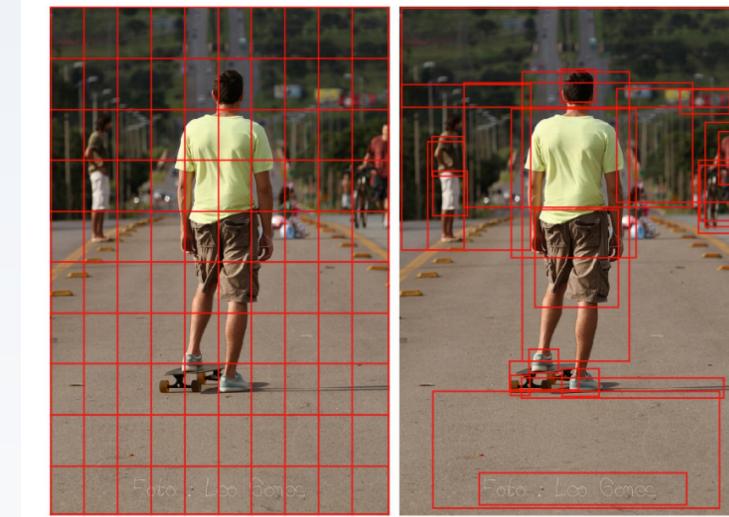


# 趋势二：融合任务相关的背景知识

## ❖ 结构语义知识

- 结构化数据生成->表格结构
- 图像描述生成->图像语义结构

Bottom-Up Modeling



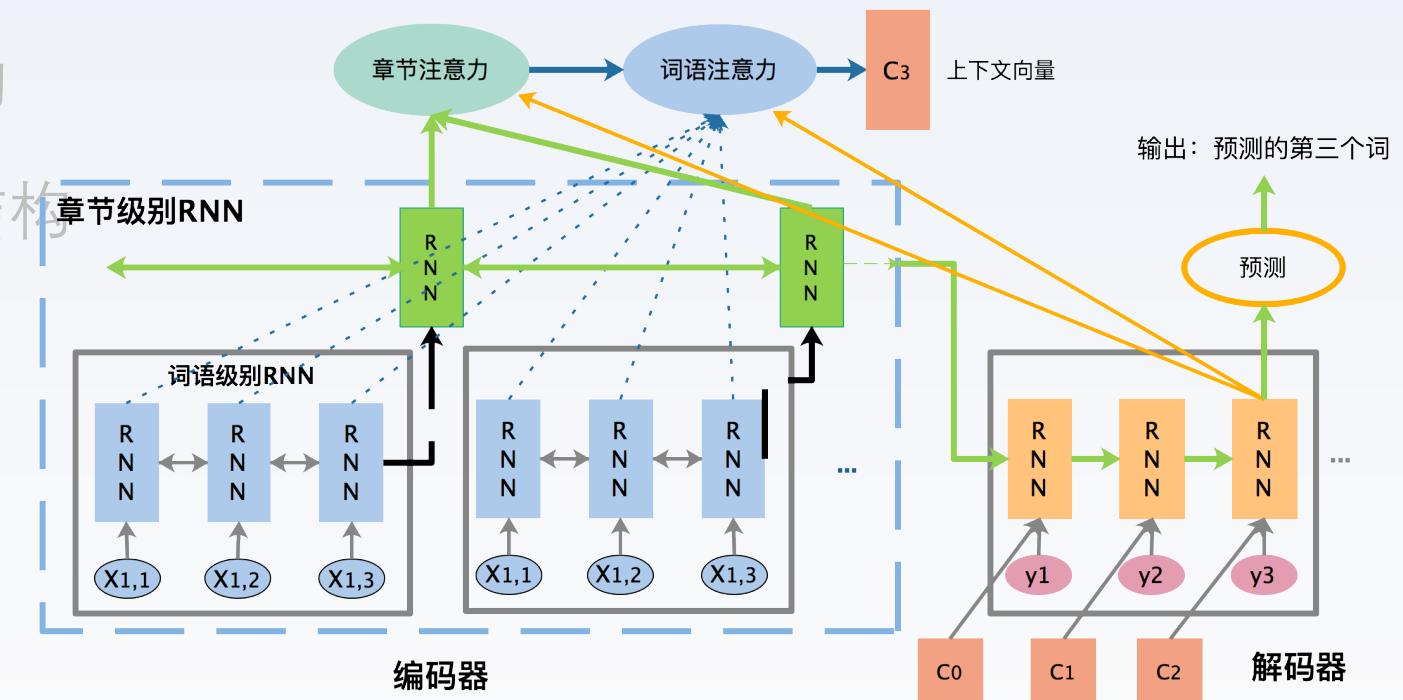


# 趋势二：融合任务相关的背景知识

## ❖ 结构语义知识

- 结构化数据生成->表格结构
- 图像描述生成->图像语义结构
- 自动文摘->篇章结构

Discourse-Aware Attention Model





# 文本生成发展趋势

- ❖ 趋势一：生成和抽取相结合
- ❖ 趋势二：融合任务相关的背景知识
- ❖ 趋势三：学习语言的不同风格表达
- ❖ 趋势四：借鉴人类写作模式





# 趋势三：学习语言的不同风格表达

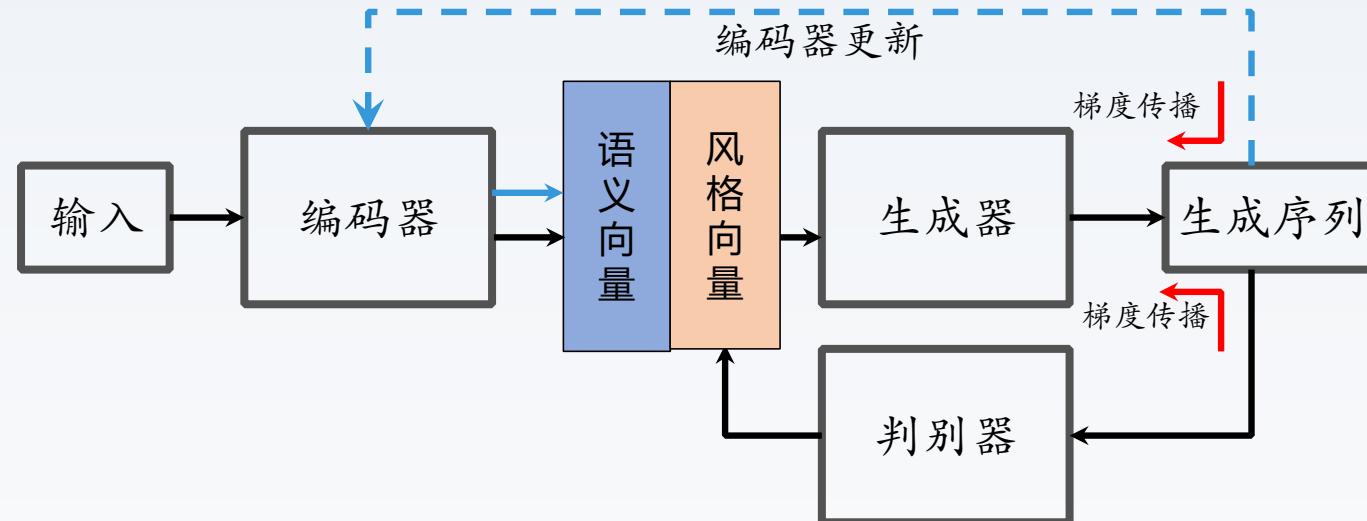
- ❖ 典型任务：语言风格迁移
- ❖ 主要问题：难以构建相同语义不同风格的训练语料
- ❖ 解决方案：利用半监督方法学习语言风格表达
  - 加入可控因子
  - 学习不同风格的解码器





# 趋势三：学习语言的不同风格表达

## ❖ 加入可控因子

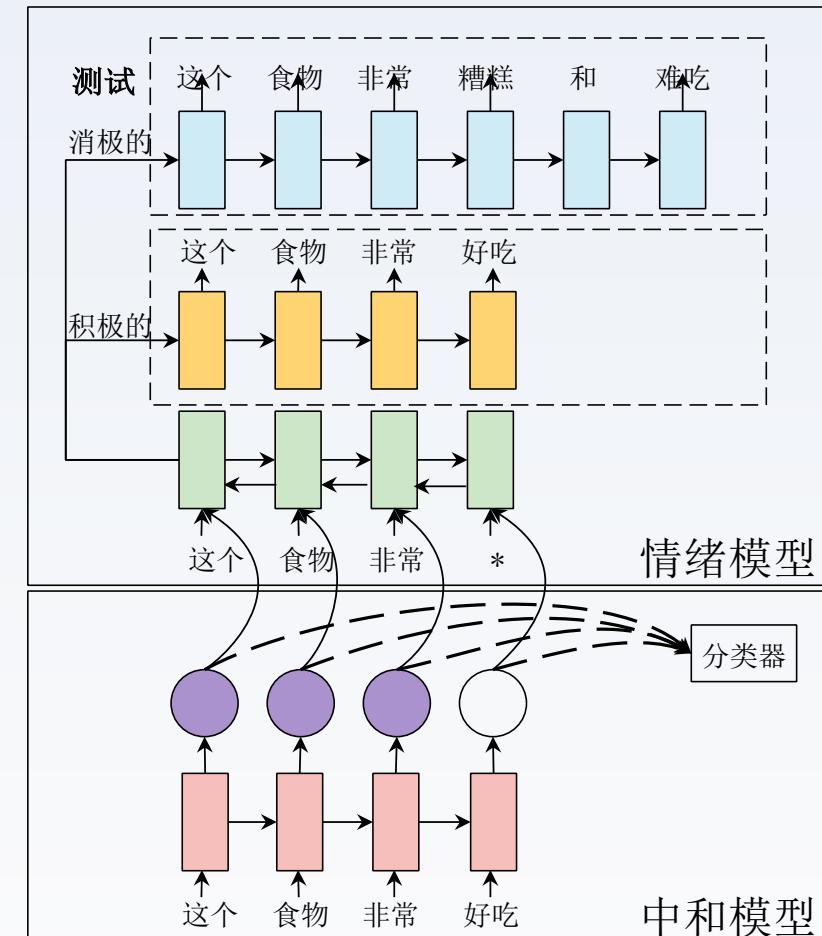




# 趋势三：学习语言的不同风格表达

## ❖ 学习不同风格解码器

➤ 热插拔





# 文本生成发展趋势

- ❖ 趋势一：生成和抽取相结合
- ❖ 趋势二：融合任务相关的背景知识
- ❖ 趋势三：学习语言的不同风格表达
- ❖ 趋势四：借鉴人类写作模式





# 趋势四：借鉴人类写作模式

- ❖ 典型任务：篇章生成、结构化数据生成
- ❖ 主要问题：长文本生成效果差，表达不连贯
- ❖ 解决方案：借鉴人类的写作方式，修改和丰富
  - 多次编辑
  - 粗粒度 - 细粒度（模版框架）

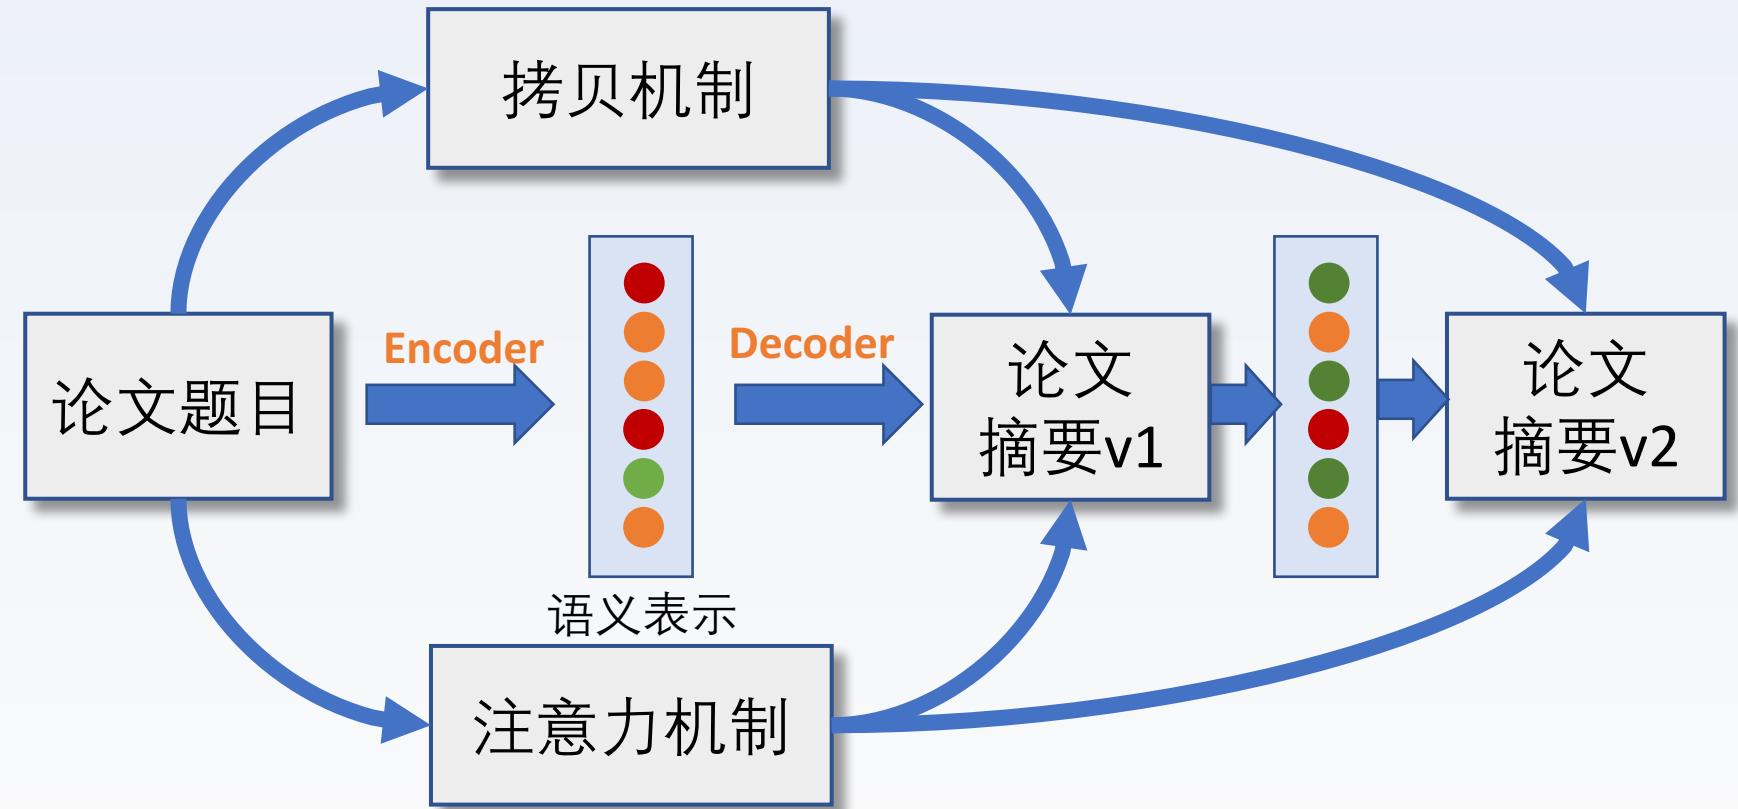




# 趋势四：借鉴人类写作模式

## ◆ 编辑网络

- 摘要生成
- 机器翻译
- 图片描述生成



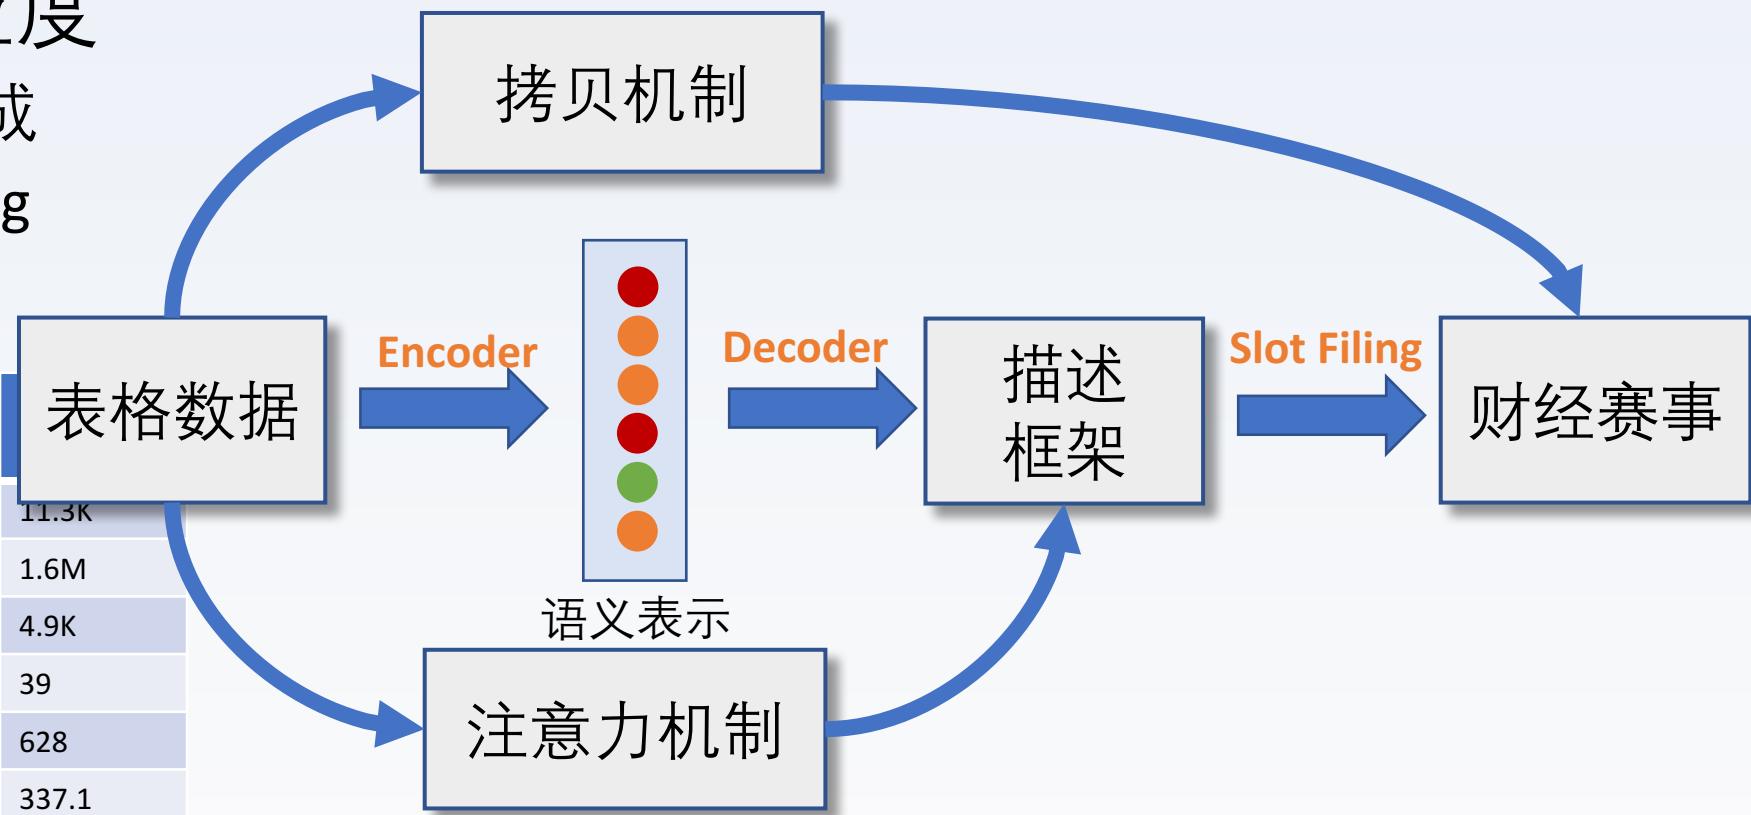


# 趋势四：借鉴人类写作模式

## ◆ 粗粒度 – 细粒度

- 结构化数据生成
- Semantic Parsing
- 图片描述生成

	天气预报 -2009	维基百科 -2016	餐馆描述 -2017	11.3K
词表	394	400	5.1K	11.3K
词数	0.9M	19M	1.0M	1.6M
实例	22.1K	728K	50K	4.9K
类型数量	10	1.7L	945	39
表格大小	191	19.7	5.6	628
平均长度	28.7	26.1	20.1	337.1





# 总结

- ❖ 文本生成技术是和任务密切相关的
- ❖ 与多媒体相融合的文本生成技术越来越深入
- ❖ 文本生成中的逻辑问题需要进一步探索
- ❖ 文本生成评价的统一标准需要进一步完善





# 谢谢！

[xfceng@ir.hit.edu.cn](mailto:xfceng@ir.hit.edu.cn)

哈尔滨工业大学  
社会计算与信息检索研究中心



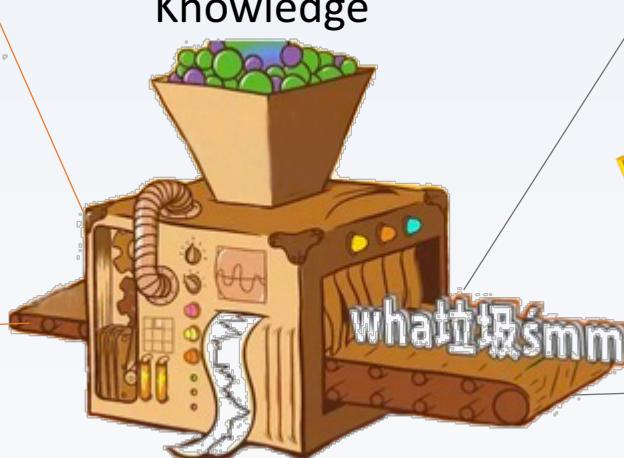


# 文本生成

Table D. NBA Draft Total Picks by Decade (1949-2008) (sorted by 90s column)									
School	00s	90s	80s	70s	60s	50s	40s	30s	Total
UCLA	13	12	6	14	4	3	1	2	51
Duke	12	15	8	3	3	0	0	36	
Arizona	11	18	4	5	0	1	3	21	
Kansas	11	19	6	3	2	1	0	0	21
Connecticut	11	9	1	0	0	0	0	0	16
Florida	15	3	2	0	1	0	3	46	
North Carolina	9	12	9	8	5	0	1	26	
Michigan State	9	8	5	3	0	1	0	19	
Texas	9	7	1	1	1	0	0	17	
Stanford	6	2	2	1	1	1	0	0	17



长沙  
臭豆腐



Task-specific  
Knowledge

卤煮是长沙最典型的美食  
库里抢断了杜兰特  
一个男在桌子旁吃东西

## Encoder-Decoder Framework

